
Um GPT para Machado de Assis

Corpus, tokenização e transferência de aprendizado com o nanoGPT

— O tamanho do problema

3–5 mi

tokens na obra completa de Machado

300 bi

tokens no treino do GPT-3

— Três perguntas

1 Do bigrama ao Transformer: quanto se ganha?

2 Caractere ou subpalavra?

3 Pré-treino em português ou modelo maior?

— Corpus

243

obras


13,4 mi

caracteres

99,1%

de cobertura em outra edição

— Resultados



1,369

bits por caractere

GPorTuguese-2 ajustado

— O que mais pesou

Engenharia

–0,09

1,725 → 1,632

Tokenizador

–0,10

1,632 → 1,530

Pré-treino em português

–0,35

1,723 → 1,369

— O mesmo início: “Capitu olhou para mim”

Sem ajuste

Eu fiquei chocado.

Eu estava tipo, malandro.

Ajustado em Machado

— *Dá-te-á lá, pensou eu; vou.*

— *Mas não diga nada.*

— *Não diga nada.*

99,5% das palavras no vocabulário de Machado

— Perguntas sobre as obras



90%

a busca acha a obra certa

1 de 8

o modelo usa a resposta que recebeu


— Próximos passos




**Ajuste por
instruções**



Embeddings
densos



Grafo de
personagens



Modelo maior
em português

- Tokenizador e pré-treino em português pesaram mais que o tamanho.
- O modelo imita o estilo, não a narrativa.
- A busca funciona; falta ensinar o modelo a responder.

Obrigado!

— Reserva: todos os resultados no teste

Modelo	Tokens	Parâm. (M)	Contexto	Treino (min)	bpc teste	Perpl. palavra
Unigrama	char	—	—	—	4,470	—
Bigrama (vídeo)	char	—	—	—	3,422	—
Trigrama	char	—	—	—	2,860	—
Char 0,8M (CPU)	char	0,8	64	2	2,691	40.260
GPT do vídeo 10,8M	char	10,8	256	52	1,725	894
nanoGPT char 10,8M	char	10,8	256	13	1,632	621
nanoGPT char 25M	char	25,5	512	30	1,565	478
BPE GPT-2, do zero	BPE en	30,0	256	17	1,574	494
BPE pt, do zero	BPE pt	30,0	256	17	1,530	415
GPT-2 124M sem ajuste	BPE en	124,0	512	0	2,804	63.001
GPorTuguese-2 sem ajuste	BPE pt	124,0	512	0	1,593	532
GPT-2 124M ajustado	BPE en	124,0	512	29	1,723	889
GPorTuguese-2 ajustado	BPE pt	124,0	512	28	1,369	220

Teste de 677 mil caracteres. O modelo de 0,8M foi treinado na CPU; os demais, numa GPU T4 do Colab.

— Reserva: bits por caractere

$$\text{bpc} = \frac{\sum_t -\log p_{\theta}(x_t \mid x_{<t})}{C \ln 2}$$

C = número de caracteres do teste. A perda por token não se compara entre tokenizadores; o bpc sim.

